

Pluralismo
Compromiso
Inclusión




Procesamiento de datos

Licenciatura en Astronomía

Clustering & Funciones de Correlación



• Clustering: Buscando estructura en los datos



ESTRUCTURA?

Distribución bimodal, trimodal...multimodal?



Clustering mediante método de mínimos cuadrados: K-means



- Particionar datos en K-subsets (clusters).
- Cada subset lo designaremos como C_k (e.g. $C_1, C_2, C_3, \dots$)
- Cada subset contiene un numero N_k de datos.
- Este método 'agrupa' los datos de tal forma que se debe minimizar la siguiente función:

$$F = \sum_{k=1}^K \sum_{i \in C_k} |x_i - \mu_k|^2$$


donde,

$$\mu_k = \frac{1}{N_k} \sum_{i \in C_k} x_i$$

representa la media de los datos en el subset C_k .



Clustering mediante método de mínimos cuadrados: K-means




• K-means clustering : ¿Cómo opera?

- 1) Se asignan valores iniciales para los centroides de cada subset (se debe asignar a-priori un numero K de subsets).
- 2) Cada dato x_i se asigna al subset más cercano, tal que se cumpla:

$$C(x_i)_k = \min_k |x_i - \mu_k|$$

- 3) Con esta primera 'agrupación' se re-calculan los centroides (nuevos μ_k).
- 4) Nuevos μ_k --> son ahora valores iniciales. Se repite el proceso desde el paso 1) hasta que no existan nuevas asignaciones para los centroides y F alcance un valor mínimo.



Idealmente, se debe repetir este proceso n-veces con distintos valores iniciales para los centroides (Paso 1). Se obtendrán n-valores para F. Aquellos centroides para el valor de F_n más pequeño son usados como asignaciones finales.

K-means clustering: Ejemplo



Considere una muestra de estrellas candidatas que podrían formar parte de la rama horizontal del cúmulo globular M28. Se dispone de las velocidades radiales para todas ellas y se desea analizar su membresía al cúmulo basado en su velocidad radial (VR).




Fig. 2. Frequency distribution of radial velocities for the 115 HB candidates in M28.

- Aparentemente, observamos dos distribuciones de VR para dos poblaciones de estrellas.
- Usamos μ_1 (VR) = 10 km/s y μ_2 (VR) = -20 km/s como valores iniciales para los centroides.
- Usamos un algoritmo de K-means en R para conocer los valores finales de los centroides (μ_1 y μ_2):

$$VR_1 = \mu_1 = (8.36 \pm 2.64) \text{ km/s}$$

$$VR_2 = \mu_2 = (-46.12 \pm 4.06) \text{ km/s}$$


K-means en Python --> `sklearn.cluster`
K-means en R --> `mixtools`



Clustering mediante Jerarquización (Hierarchical Clustering)




- A diferencia del método anterior, no se necesita definir a-priori el número K de subsets.
- Este método construye una jerarquía de clusters (que puede ser aglomerativa o divisoria).
- Comienza dividiendo la muestra de datos en N-clusters (con N: número de elementos en la muestra original).
- Uno en uno se van agrupando dos clusters en función de su distancia (parámetro de similitud).
- Proceso se repite hasta obtener un solo cluster que contiene todos los datos.



DENDROGRAMA



Hierarchical Clustering: ¿Cómo opera?



Paso 1. Se agrupan los clusters más similares entre sí, usando su distancia como parámetro de 'similitud'. Se puede elegir entre diversas opciones:

- Minimizar la distancia entre dos clusters:

$$d_{\min}(C_k, C_{k'}) = \min_{x \in C_k, x' \in C_{k'}} |x - x'|$$

- Maximizar la distancia entre dos clusters:


$$d_{\max}(C_k, C_{k'}) = \max_{x \in C_k, x' \in C_{k'}} |x - x'|$$

- Distancia entre los centroides:

$$d_{\text{cent}}(C_k, C_{k'}) = |\mu_k - \mu_{k'}|$$



Hierarchical Clustering: ¿Cómo opera?



Paso 2 y de allí en adelante. Se repite el proceso con los clusters restantes y los nuevos.

Paso n. Solo queda un cluster con todos los datos.

Hierarchical Clustering: Ejemplo




Figure 6.15. An approximate Euclidean minimum spanning tree over the two-dimensional projection of the SDSS Great Wall. The upper panel shows the input points, and the middle panel shows the dendrogram connecting them. The lower panel shows clustering based on this dendrogram, created by removing the largest 10% of the graph edges, and keeping the remaining connected clusters with 30 or more members.

➡ La Gran Muralla:
Filamento galáctico
compuesto de tres
supercúmulos masivos
de galaxias.

➡ DENDROGRAMA


➡ Dendrograma donde
se han removido
algunos de los puntos mas
cercanos a dos clusters y
donde cada cluster tiene
un mínimo de 30 elementos
(galaxias).

Hierarchical Clustering en
Python:
`sklearn.cluster`
`scipy.cluster`

• Funciones de Correlación: ¿Son los datos de un cluster una agrupación 'verdadera'?



¿A que grado la distribución de puntos de un cluster difiere de una distribución aleatoria de puntos?



Distribución aleatoria


• Función de Correlación de dos puntos

- La probabilidad de encontrar un punto en un elemento de volumen dV , es directamente proporcional a la densidad de puntos ρ .
- La probabilidad de encontrar dos puntos en dV que se encuentren separados una distancia r , está dada por:

$$dP = \rho dV$$

$$dP_{12} = \rho(1 + \xi(r))dV$$

- La función $\xi(r)$ se conoce como **función de correlación**.
- $\xi(r)$ mide un **exceso de probabilidad** (por sobre una distribución aleatoria sin agrupar) de encontrar dos puntos separados una distancia r .



• Función de Correlación de dos puntos



- $\xi(r)$ puede ser positiva, negativa o nula para indicar si existe una correlación, anticorrelación o una aleatoriedad.
- ¿Como obtenemos un estimador para $\xi(r)$?

El método mas sencillo consiste en calcular el exceso o deficit de pares de puntos (puntos separados entre ellos una distancia r) dentro de un cierto volumen (o área) y comparar este valor con una distribución aleatoria usando el mismo volumen (o área).

Sean:

$DD(r)$: numero de pares (para un cierto r) en los datos.

$RR(r)$: numero de pares (para un cierto r) en la distribución aleatoria.



$$\hat{\xi}(r) = \frac{DD(r)}{RR(r)} - 1$$

Peebles & Hauser, 1974

• Función de Correlación de dos puntos




Un estimador mas reciente y con menor varianza:

$$\hat{\xi}(r) = \frac{DD(r) - 2DR(r) + RR(r)}{RR(r)}$$

Landy & Szalay, 1993

donde $DR(r)$: numero pares (para un cierto r), formado por un punto de la data y uno aleatorio.

Notar que para cada valor de r se obtendrá un valor para el estimador de la función de correlación $\hat{\xi}(r)$



Para este caso, la función de correlación es lineal y positiva.

• Función de Correlación de dos puntos




En estudios sobre la distribución de galaxias en el Universo, la función de correlación se expresa como una ley de potencias:

$$\xi(r) = \left(\frac{r}{r_0} \right)^{-\gamma}$$

siendo r_0 la escala de longitud del cúmulo en cuestión.

Para galaxias en el Universo local (dentro de los 300 Mpc) $r_0 \sim 6$ Mpc y $\gamma \sim 1.8$



Galaxy two-point correlation function, $\xi(r)$, at the present epoch as a function of separation r . Red symbols (with vanishingly small Poisson error bars) show measurements for model galaxies brighter than $M_K = -23$, where M_K is the magnitude in the K-band. Data for the large spectroscopic redshift survey 2dFGRS (ref. 28) are shown as blue diamonds together with their 1- σ error bars. The SDSS (ref. 34) and APM (ref. 31) surveys give similar results. Both for the observational data and for the simulated galaxies, the correlation function is very close to a power law for $r > 20h^{-1}$ Mpc. By contrast, the correlation function for the dark matter (dashed green line) deviates strongly from a power law.

• Función de Correlación de dos puntos



Dada la dificultad de determinar con certeza la distancia entre galaxias mas allá de nuestro Universo local, normalmente se puede trabajar con una función de correlación angular (considerando las distancias angulares aparentes de las galaxias proyectadas en el cielo).

Para este caso:

$$\xi = \omega(\theta) = \left(\frac{\theta}{\theta_0} \right)^{1-\gamma}$$



Hubble Ultra Deep Field image

• Función de Correlación de dos puntos




Figure 6.17. The two-point correlation function of SDSS spectroscopic galaxies in the range $0.08 < z < 0.12$, with $m < 17.7$. This is the same sample for which the luminosity function is computed in figure 4.10. Errors are estimated using ten bootstrap samples. Dotted lines are added to guide the eye and correspond to a power law proportional to $\theta^{-0.8}$. Note that the red galaxies (left panel) are clustered more strongly than the blue galaxies (right panel).



Estamos
comprometidos con la
Región de Coquimbo



4 AÑOS ACREDITADA
GESTIÓN INSTITUCIONAL | DESDE DICIEMBRE 2017
DOCENCIA DE PREGRADO |
VINCULACIÓN CON EL MEDIO | HASTA DICIEMBRE 2021

www.ucentral.cl