

Pluralismo
Compromiso
Inclusión



Procesamiento de datos





Licenciatura en Astronomía

Regresión y Ajustes de Modelos




• Regresión: Como se relacionan mis datos?

Regresión lineal





• Regresión: Como se relacionan mis datos?



CURVA (o MODELO) de regresión

$$y_i = \theta_0 + \theta_1 x_i + \epsilon_i$$



regresión lineal simple
(linea recta)

$$y_i = \theta_0 + \theta_1 x_i + \theta_2 x_i^2 + \theta_3 x_i^3 + \dots + \theta_n x_i^n + \epsilon_i$$

regresión polinomial de grado n.

- Set de parámetros del modelo desconocidos θ_n .
- x_i es un vector de variables predictivas (variable independiente).
- y_i es variable dependiente (variable de respuesta).
- ϵ_i error aleatorio en la variable de respuesta, se asume que $\epsilon_i \sim N(0, \sigma^2)$



• Regresión: Estimación de los parámetros

Existen diversos métodos estadísticos para estimar los parámetros de un regresión lineal, lo más comunes:

- Método de mínimos cuadrados.

Minimiza la suma de los cuadrados de los errores ε_i

- Método de máxima verosimilitud

Maximiza la función de verosimilitud.

- Inferencia Bayesiana

Maximiza la distribución a posteriori.

} Curso de P&E

Caso 1.

Regresión lineal simple (linea recta)

$$y_i = \theta_0 + \theta_1 x_i + \epsilon_i$$



$$\theta_0 = y' - \theta_1 x'$$

x' e y' son los valores medios
de las observaciones x_i e y_i , respectivamente.

$$\theta_1 = \frac{\sum_{i=1}^n (x_i - x')(y_i - y')}{\sum_{i=1}^n (x_i - x')^2}$$



• Regresión: Estimación de los parámetros



Las incertezas (varianzas) en los estimadores de estos parámetros estarán dados por:

$$Var(\theta_0) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - x')^2}$$

$$Var(\theta_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - x')^2}$$

Teorema de Gauss- Markov

donde,

$$\sigma^2 = \frac{\sum_{i=1}^n \epsilon_i^2}{n-2}$$



Estimador para la varianza de la regresión (también conocida como varianza residual)

• Regresión: Estimación de los parámetros



Caso 2.

Regresión polinomial



$$y_i = \theta_0 + \theta_1 x_i + \theta_2 x_i^2 + \theta_3 x_i^3 + \dots + \theta_n x_i^n + \epsilon_i$$

Para este caso, debemos operar matricialmente:

$$Y = \begin{bmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_{n-1} \end{bmatrix} ; \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_{n-1} \end{bmatrix} ; M = \begin{bmatrix} 1 & x_0 & x_0^2 & x_0^3 & \dots \\ 1 & x_1 & x_1^2 & x_1^3 & \dots \\ 1 & x_2 & x_2^2 & x_2^3 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 & x_n^3 & \dots \end{bmatrix} ; \epsilon = \begin{bmatrix} \epsilon_0^2 & 0 & 0 & 0 \\ 0 & \epsilon_1^2 & 0 & 0 \\ 0 & 0 & \epsilon_2^2 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \epsilon_{n-1}^2 \end{bmatrix} \Rightarrow Y = M \theta + \epsilon$$



• Regresión: Estimación de los parámetros



Los estimadores para los parámetros por máxima verosimilitud se obtienen luego de resolver matricialmente para θ :

$$\theta = (M^T C^{-1} M)^{-1} (M^T C^{-1} Y)$$

Las incertezas en la estimación de los parámetros, quedarán dadas por la matriz:

$$\Sigma_{\theta} = [M^T C^{-1} M]^{-1}$$

Regresión lineal



Redshift (z) vs.
modulo de
distancia para
100 SNs
(simuladas
desde un modelo
cosmológico).




Figure 8.2. Various regression fits to the distance modulus vs. redshift relation for a simulated set of 100 supernovas, selected from a distribution $p(z) \propto (z/z_0)^2 \exp[(z/z_0)^{1.5}]$ with $z_0 = 0.3$.



¿A que grado es 'bueno' mi modelo de regresión?



Bondad del Modelo.

Test de chi-cuadrado (χ^2 - squared test)

Definición.

Suponga que usted tiene un set de ν variables independientes.

Cada una de estas variables (x_i , $i=1, \dots, \nu$) se distribuye normalmente con una media μ_i y una varianza σ_i^2 .

Se define la cantidad conocida como chi-cuadrado (χ^2):

$$\chi^2 \equiv \underbrace{\frac{(x_1 - \mu_1)^2}{\sigma_1^2}}_{\approx 1} + \underbrace{\frac{(x_2 - \mu_2)^2}{\sigma_2^2}}_{\approx 1} + \dots + \underbrace{\frac{(x_\nu - \mu_\nu)^2}{\sigma_\nu^2}}_{\approx 1} = \sum_{i=1}^{\nu} \frac{(x_i - \mu_i)^2}{\sigma_i^2}$$



Asumiendo fluctuaciones aleatorias de x_i alrededor de su media μ_i

• Test de Chi-cuadrado



Si hemos elegido correctamente los valores de μ_i y σ_i para cada variable, entonces deberíamos esperar que:

$$\chi^2 \approx 1+1+1.... \nu\text{-veces} \approx \nu$$

Si pudiéramos repetir el experimento un numero muy grande de veces (distintos valores para las variables cada vez) y calculamos sus χ^2 cada vez




Figure 1 — The chi-square distribution for $\nu = 2, 4$, and 10.

• Test de Chi-cuadrado




Figure 1 — The chi-square distribution for $\nu = 2, 4$, and 10 .

DISTRIBUCION DE PROBABILIDAD DE χ^2
CON ν GRADOS DE LIBERTAD

$$f(\chi^2) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} e^{-\chi^2/2} (\chi^2)^{(\nu/2)-1}$$

- El valor esperado (valor medio) de χ^2 es ν .
- Su varianza es 2ν
- ν es siempre entero positivo.
- Para ν altos $\rightarrow$ la distribución se aproxima a una distribución normal.

¿Que sucede si alguna de mis variables están relacionadas entre si?

Si esto sucede, entonces al menos una de las variables se puede escribir en función de otra y esto reduce los términos de la suma inicial y por lo tanto se reduce el numero de grados de libertad de la distribución χ^2 .

Ahora, el numero de grados de libertad ➡ $\nu = N - k$

siendo N: numero de variables (u observaciones) y k: numero de relaciones entre variables.

• Test de Chi-cuadrado




A partir de:

$$\chi^2 \approx 1+1+1.... \nu\text{-veces} \approx \nu$$

Notar que

$$\frac{\chi^2}{\nu} \approx 1$$



siempre y cuando hallamos elegido 'correctamente' los parámetros μ_i y σ_i^2 para las variables (modelo correcto).

χ^2 NORMALIZADO (ó χ^2 por grados de libertad ó χ^2 reducido)

• Test de Chi-cuadrado



Consideremos ahora que nuestras variables x_i son nuestras observaciones y que tenemos un modelo teórico para explicar las observaciones con sus correspondientes parámetros.


Si calculamos el χ^2 / ν para nuestras observaciones (usando los parámetros del modelo):

- Si $\chi^2 / \nu \approx 1$ ➡ Buen modelo!
- Si χ^2 / ν es muy grande ➡ el modelo es insuficiente para representar los datos (los errores –las varianzas σ_i han sido bajoestimados).
- Si χ^2 / ν es muy pequeño ➡ se han sobreestimado los errores (σ_i).

• Test de Chi-cuadrado

Considere un set de observaciones de la luminosidad de una estrella.

Nuestro modelo considera que la luminosidad de la estrella no varia ($L = 10 = \mu = \text{media}$) y que la dispersión en los datos se debe unicamente a errores de medición.





**Estamos
comprometidos con la
Región de Coquimbo**



4 AÑOS ACREDITADA
GESTIÓN INSTITUCIONAL | DESDE DICIEMBRE 2017
DOCENCIA DE PREGRADO |
VINCULACIÓN CON EL MEDIO | HASTA DICIEMBRE 2021

www.ucentral.cl