


Pluralismo
Compromiso
Inclusión



Procesamiento de datos

Licenciatura en Astronomía

Regresión y Ajustes de Modelos



- Valores extremos fuera del rango esperado y que no siguen la tendencia del resto de los datos

¿Como tratarlos?

OPCION 1. Remover

OPCION 2. Considerar un modelo que los incluya.

Opción 1. Remover

Método IQR (Diagramas de Caja y Bigotes – Box and Whiskers plot)

- Se agrupan datos por cuartiles:

Q1: 25%


Q2: 50% (mediana)

Q3: 75%

- Se definen los valores máximos y mínimos para los llamados 'bigotes':

mín = $1.5 * IQR$ (por debajo de Q1)

máx = $1.5 * IQR$ (por encima de Q3)




50% de los datos
esta en la caja
 $IQR = Q_3 - Q_1$

Cualquier valor por sobre estos límites se considera un outlier.




Outliers: atípicos y extremos



Valores atípicos

Valores extremos
(por lo general igual
o mayores a $3 \times \text{IQR}$)



Estadística de boxplot para un set de cometas basados en sus abundancias moleculares.



Outliers figuran nombrados.

Opción 2. Considerar un modelo de regresión que incluya outliers.

Algunos modelos robustos usados comúnmente:

→ Modelo de Regresión de Huber

- Asigna un peso estadístico menor a aquellos puntos considerados como outliers.
- Clasifica como outliers usando los residuos (ε_i).



Python (sklearn):

regresión lineal simple – `LinearRegression()`

regresión de Huber – `HuberRegressor()`

Python (astropy.modeling):

<https://docs.astropy.org/en/stable/modeling/index.html>

→ Modelo de Regresión mediante algoritmo RANSAC



- Algoritmo de iteración.
- Selecciona al azar un subset de datos y genera un modelo de regresión.
- Usando este ultimo, calcula los residuos para todos los datos.

inliers: datos que tienen residuos menores a un valor umbral establecido.

outliers: todos los restantes.


- El modelo final es elegido como aquel que considera el mayor numero de inliers.

```
Python (sklearn)  
RANSACRegressor()
```




→ Modelo de Regresión de Thein-Len


- Simultáneamente realiza múltiples regresiones sobre n-subsets de datos de tamaño p.
- Determina la **mediana** para cada uno de los parámetros encontrados en las regresiones anteriores (i.e. pendiente, intercepto).
- Modelo final: utiliza estos parámetros.
- Involucra mayor tiempo de cómputo.



• Comparando modelos



Comparison of robust regression algorithms



	model	coefficient
0	original_coef	64.59
1	linear_regression	8.77
2	huber_regression	37.52
3	ransac_regression	62.85
4	theilsen_regression	59.49

Table 1. The comparison of the coefficients of the different models fitted to the data with outliers



Estamos
comprometidos con la
Región de Coquimbo



4 AÑOS ACREDITADA
GESTIÓN INSTITUCIONAL | DESDE DICIEMBRE 2017
DOCENCIA DE PREGRADO |
VINCULACIÓN CON EL MEDIO | HASTA DICIEMBRE 2021

www.ucentral.cl