

Pluralismo
Compromiso
Inclusión



Licenciatura en Astronomía

Procesamiento de datos/data mining



Series de tiempo



Es un conjunto de observaciones sobre valores que toma una variable en diferentes momentos del tiempo.

Diferentes comportamiento de los datos a través del tiempo: tendencia, forma definida o aleatoria, variaciones estacionales (anual, semestral, etc).

Tareas principales:

Tu texto aquí 1

- Caracterizar la presunta correlación temporal entre diferentes valores de “y”
- Predecir los valores futuros de “y”





Series de tiempo



Es una secuencia de un número observaciones o datos “ N ” ordenadas y equidistantes cronológicamente sobre una (serie univariante) o varias características (serie multivariante) de una unidad observable en diferentes en diferentes instancias.

Series de tiempo univariantes: $y_1, y_2, \dots, y_N; (y_t)_{t=1}^N; (y_t : t = 1, \dots, N)$

y_t es la observación número t ($1 \leq t \leq N$) de la serie.

N es el número de observaciones de la serie completa.

Las N observaciones $y_1, y_2, \dots, y_N$ pueden considerarse en un vector $\mathbf{y} \equiv [y_1, y_2, \dots, y_N]'$ de orden $N \times 1$.



Series de tiempo multivariantes: $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N; (\mathbf{y}_t)_{t=1}^N; (\mathbf{y}_t : t = 1, \dots, N),$

donde $\mathbf{y}_t \equiv [y_{t1}, y_{t2}, \dots, y_{tM}]'$ ($M \geq 2$) es la observación número t ($1 \leq t \leq N$) de la serie.

N es el número de observaciones de la serie.



Las N observaciones $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N$ pueden recogerse en una matriz $\mathbf{Y}$ de orden $N \times M$:

$$\mathbf{Y} \equiv \begin{bmatrix} \mathbf{y}'_1 \\ \mathbf{y}'_2 \\ \vdots \\ \mathbf{y}'_N \end{bmatrix} \equiv \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1M} \\ y_{21} & y_{22} & \cdots & y_{2M} \\ \vdots & \vdots & & \vdots \\ y_{N1} & y_{N2} & \cdots & y_{NM} \end{bmatrix},$$

y_{tj} es la observación número t ($1 \leq t \leq N$) sobre la característica o variable número j ($1 \leq j \leq M$), que es la misma en todo momento t .




• Ejemplos de Series de tiempo




• Componentes de las series de tiempo

- **Ciclo:** caracterizado por oscilaciones alrededor de la tendencia con una larga duración. E.g., fenómenos climáticos.




• Componentes de las series de tiempo

- **Ciclo:** caracterizado por oscilaciones alrededor de la tendencia con una larga duración. E.g., fenómenos climáticos.
- **Estacionalidad:** movimiento periódico producido dentro de un periodo corto y conocido.




• Componentes de las series de tiempo

- **Ciclo:** caracterizado por oscilaciones alrededor de la tendencia con una larga duración. E.g., fenómenos climáticos.
- **Estacionalidad:** movimiento periódico producido dentro de un periodo corto y conocido.
- **Tendencia:** comportamiento predominante de la serie. Puede definirse como el cambio de la media a lo largo de un extenso periodo de tiempo.



• Componentes de las series de tiempo


- **Ciclo:** caracterizado por oscilaciones alrededor de la tendencia con una larga duración. E.g., fenómenos climáticos.
- **Estacionalidad:** movimiento periódico producido dentro de un periodo corto y conocido.
- **Tendencia:** comportamiento predominante de la serie. Puede definirse como el cambio de la media a lo largo de un extenso periodo de tiempo.
- **Nivel:** El nivel de una serie es una medida local de tendencia central.



Componentes de las series de tiempo




- **Ciclo:** caracterizado por oscilaciones alrededor de la tendencia con una larga



- **Nivel:** El nivel de una serie es una medida local de tendencia central.

Componentes de las series de tiempo

- **Ciclo:** caracterizado por oscilaciones alrededor de la tendencia con una larga duración. E.g., fenómenos climáticos.
- **Estacionalidad:** movimiento periódico producido dentro de un periodo corto y conocido.
- **Tendencia:** comportamiento predominante de la serie. Puede definirse como el cambio de la media a lo largo de un extenso periodo de tiempo.
- **Nivel:** El nivel de una serie es una medida local de tendencia central.




- **Aleatorio:** movimientos erráticos que no siguen un patrón específico
→ Componente impredecible.



Procesos estacionarios

- Serie temporal estable
 - media y la variabilidad son constantes a lo largo del tiempo.
- Los valores de la serie tienden a oscilar alrededor de una media constante.
- Variabilidad con respecto a la media también permanece constante.




Stationary series

fuelle: www.analyticsvidhya.com/




Procesos estacionarios

- Serie temporal estable
→ media y la variabilidad son constantes a lo largo del tiempo.
- Los valores de la serie tienden a oscilar alrededor de una media constante.
- Variabilidad con respecto a la media también permanece constante.




https://www.cepal.org/sites/default/files/courses/files/s/01_1_conociendo_una_serie_de_tiempo.pdf





Procesos no estacionarios

- Series en las cuales la media y/o variabilidad cambian en el tiempo.
 - Los cambios en la media → determinan tendencia a crecer o decrecer a largo plazo
- por lo que la serie no oscila alrededor de un valor constante.



Non-Stationary series



fuelle: www.analyticsvidhya.com/



Procesos no estacionarios

- Series en las cuales la media y/o variabilidad cambian en el tiempo.
- Los cambios en la media → determinan tendencia a crecer o decrecer a largo plazo

→ por lo que la serie no oscila alrededor de un valor constante.





Las técnicas de predicción se pueden agrupar en dos:

Métodos cualitativos: el pasado no proporciona una información directa sobre el fenómeno considerado, e.g., lanzamiento de nuevos productos.

Métodos cuantitativos: se extrae toda la información posible contenida en los datos y se considera la conducta en el pasado, para así realizar predicciones sobre el futuro.




Las técnicas de predicción se pueden agrupar en dos:

Métodos cualitativos: el pasado no proporciona una información directa sobre el fenómeno considerado, e.g., lanzamiento de nuevos productos.

Métodos cuantitativos: se extrae toda la información posible contenida en los datos y se considera la conducta en el pasado, para así realizar predicciones sobre el futuro.



Métodos clásicos



http://humanidades.cchs.csic.es/cchs/web_UAE/tutoriales/PDF/SeriesTemporales.pdf

Modelos de suavizamiento



Técnicas utilizadas para eliminar el ruido de los datos y así extraer características importantes y sus los componentes (e.g., tendencia, estacionalidad, etc.).

Además, interpolar valores y/o realizar pronósticos.

Modelos de suavizamiento



Técnicas utilizadas para eliminar el ruido de los datos y así extraer características importantes y sus los componentes (e.g., tendencia, estacionalidad, etc.).

Además, interpolar valores y/o realizar pronósticos.

Ejemplos:

- **Promedio móvil ponderado (WMA)**
- **Suavizado exponencial simple**
- Suavizado exponencial doble
- Suavizado exponencial lineal
- Suavizado exponencial triple



• Media móvil ponderada (WMA)

- Indicador técnico que determina la dirección de la tendencia.
- Calcula el promedio de los valores de entrada dados durante períodos de tiempo específicos asignando un mayor peso a los datos recientes y menos peso a los datos pasados.

$$Y_t = \frac{\sum_{i=1}^N W_i X_{t-i}}{\sum_{i=1}^N W_i}$$

W_i : i -ésima posición factor de peso

$\{X_t\}$: serie de tiempo original

$\{Y_t\}$: serie de tiempo suavizada

Y_t utiliza los valores anteriores de N de las observaciones $\{X_{t-1}, X_{t-2}, \dots, X_{t-N}\}$




Media móvil ponderada (WMA)



- Indicador técnico que determina la dirección de la tendencia.
- Calcula el promedio de los valores de entrada dados durante períodos de tiempo específicos asignando un mayor peso a los datos recientes y menos peso a los datos pasados.

$$Y_t = \frac{\sum_{i=1}^N W_i X_{t-i}}{\sum_{i=1}^N W_i}$$





Suavizado Simple Exponencial



Similar al WMA pero el tamaño de la ventana es infinito y los factores de ponderación disminuyen exponencialmente.

$$Y_1 = X_1$$

$$Y_2 = (1 - \alpha)Y_1 + \alpha X_2 = X_1$$

$$Y_3 = (1 - \alpha)Y_2 + \alpha X_3 = (1 - \alpha)X_1 + \alpha X_2$$

$$Y_4 = (1 - \alpha)Y_3 + \alpha X_4 = (1 - \alpha)^2 X_1 + \alpha(1 - \alpha)X_2 + \alpha X_3$$

$$Y_5 = (1 - \alpha)^3 X_1 + \alpha(1 - \alpha)^2 X_2 + \alpha(1 - \alpha)X_3 + \alpha X_4$$

$$Y_{T+1} = (1 - \alpha)^T X_1 + \alpha \sum_{i=1}^T (1 - \alpha)^{T-i} X_{i+1}$$

...

$$Y_{T+m} = Y_{T+1}$$

α es el factor de suavizado con valores de $0 < \alpha < 1$




Suavizado Simple Exponencial



Similar al WMA pero el tamaño de la ventana es infinito y los factores de ponderación disminuyen exponencialmente.

$$\begin{aligned}Y_1 &= X_1 \\Y_2 &= (1 - \alpha)Y_1 + \alpha X_2 = X_1 \\Y_3 &= (1 - \alpha)Y_2 + \alpha X_3 = (1 - \alpha)X_1 + \alpha X_3 \\Y_4 &= (1 - \alpha)Y_3 + \alpha X_4 = (1 - \alpha)^2 X_1 + \alpha(1 - \alpha)X_3 + \alpha X_4 \\Y_5 &= (1 - \alpha)^3 X_1 + \alpha(1 - \alpha)^2 X_2 + \alpha(1 - \alpha)X_3 + \alpha X_4 \\&\vdots \\Y_{T+m} &= Y_{T+1}\end{aligned}$$

α es el factor de suavizado con $\alpha = 0.8$



Datos mensuales de ventas $\alpha = 0.8$.



Función de Autocorrelación (ACF)




Mide la correlación entre dos variables separadas por k periodos.

$$\rho_j = \text{corr}(X_j, X_{j-k}) = \frac{\text{cov}(X_j, X_{j-k})}{\sqrt{V(X_j)}\sqrt{V(X_{j-k})}}$$

La función de autocorrelación simple tiene las siguientes propiedades:

- $\rho_0 = 1$
- $-1 \leq \rho_j \leq 1$
- Simetría $\rho_j = \rho_{-j}$



Estacionario $\rightarrow$ no tiene tendencia, una constante varianza, y autocorrelación. La función de autocorrelación decrece rápidamente cerca de 0.



Función de Autocorrelación (ACF)




Mide la correlación entre dos variables separadas por k periodos.

$$\rho_j = \text{corr}(X_j, X_{j-k}) = \frac{\text{cov}(X_j, X_{j-k})}{\sqrt{V(X_j)}\sqrt{V(X_{j-k})}}$$

La función de autocorrelación simple tiene las siguientes propiedades:

- $\rho_0 = 1$
- $-1 \leq \rho_j \leq 1$
- Simetría $\rho_j = \rho_{-j}$



Para valores aleatorios es cercano a 0.



Función de Autocorrelación (ACF)




Mide la correlación entre dos variables separadas por k periodos.


$$\rho_j = \text{corr}(X_j, X_{j-k}) = \frac{\text{cov}(X_j, X_{j-k})}{\sqrt{V(X_j)}\sqrt{V(X_{j-k})}}$$

La función de autocorrelación simple tiene las siguientes propiedades:

- $\rho_0 = 1$
- $-1 \leq \rho_j \leq 1$
- Simetría $\rho_j = \rho_{-j}$



https://www.cepal.org/sites/default/files/courses/files/01_1_conociendo_una_serie_de_tiempo.pdf



Decrece lentamente para series de tiempo no estacionarias.



Función de Autocorrelación (ACF)




Mide la correlación entre dos variables separadas por k periodos.

$$\rho_j = \text{corr}(X_j, X_{j-k}) = \frac{\text{cov}(X_j, X_{j-k})}{\sqrt{V(X_j)}\sqrt{V(X_{j-k})}}$$

La función de autocorrelación simple tiene las siguientes propiedades:

- $\rho_0 = 1$
- $-1 \leq \rho_j \leq 1$
- *Simetría* $\rho_j = \rho_{-j}$



Cuando la serie de tiempo tiene tendencia y estacionalidad → mezcla de ambos efectos




• Función de Autocorrelación parcial (PACF)



Cambios en la correlación para diferentes mediciones.

→ La correlación final entre las observaciones será la obtenida al parcializar la autocorrelación.

Útil para especifica en modelos de regresión con series de tiempo





Procesos Lineales Estacionarios

- Procesos autorregresivos (AR, p)
- Proceso de medias móviles (MA, q)
- Proceso autorregresivo de medias móviles $ARMA(p, q)$

Procesos Lineales no Estacionarios

- Proceso autorregresivo integrado y de media móvil $ARIMA(p, d, q)$



• Procesos autorregresivos (AR, p)




$$X_t = a_t + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p}$$

Un proceso de orden p es un proceso en el que la variable X_t se obtiene efectuando una regresión sobre valores pasados de la misma.

La función de autocorrelación simple de un modelo autorregresivo no se corta, tiende a cero rápidamente, exponencialmente.

Función de autocorrelación simple (FAS)





• Procesos de medias móviles (MA, q)



$$X_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

Un proceso MA de orden q es un proceso en el que la variable X_t se obtiene como un promedio de variables de ruido blanco a_i , siendo θ_i sus coeficientes de ponderación.



• Proceso autorregresivo de medias móviles $ARMA(p, q)$



Sea $\{\epsilon_t\}$ un proceso ruido blanco; el proceso estocástico

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$

con $\phi_p, \theta_q \neq 0$ es llamado un proceso $ARMA(p, q)$.

Es la suma de un proceso autorregresivo de orden p y uno de medias móviles de orden q .

El modelo $ARMA$ (Auto Regressive Moving Average) es un modelo autorregresivo estacionario donde las variables independientes siguen tendencias estocásticas.



• Proceso autorregresivo integrado y de media móvil *ARIMA* (p, d, q)

ARIMA Una serie de tiempo no estacionaria en nivel (serie con tendencia) se consigue que la serie pase a ser estacionaria a través del diferencial.

→ Diferenciar una serie X_t consiste en aplicarle el operador diferencial simple:

$$\nabla X_t = X_t - X_{t-1}$$

Puede que siga siendo no estacionaria → una nueva diferencial.

Notación de modelos *ARIMA* (p, d, q) , con d : número de diferencial que se efectúan sobre la serie original antes de ajustar un ARMA.

ARIMA: autoregressive integrated moving average.



Universidad
Central



4 AÑOS ACREDITADA
GESTIÓN INSTITUCIONAL | DESDE DICIEMBRE 2017
DOCENCIA DE PREGRADO | HASTA DICIEMBRE 2021
VINCULACIÓN CON EL MEDIO

www.ucentral.cl